

МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«Южно-Уральский государственный университет (национальный исследовательский университет)»
Институт естественных и точных наук
Кафедра прикладной математики и программирования

Отчет по лабораторной работе № 5
Начальная настройка весов полностью связанных
и сверточных нейронных сетей

по дисциплине

«Современные нейросетевые технологии»

ЮУрГУ - 01.04.02. 2025. 306/010. Р

Руководитель, преподаватель

_____/ Д.М. Кичеев /

« ____ » июня 2025 г.

Автор

студент группы ИЕТН - ЕТ-122

_____/ О.В. Ростова /

« ____ » июня 2025 г.

Челябинск 2025

Цель настоящей работы состоит в том, чтобы использовать методы обучения без учителя для настройки начальных значений весов сетей, построенных при выполнении предшествующих практических работ.

Выполнение практической работы предполагает решение следующих **задач**:

1. Выбор архитектур нейронных сетей, построенных при выполнении предшествующих практических работ.
2. Выбор методов обучения без учителя для выполнения настройки начальных значений весов сетей.
3. Применение методов обучения без учителя к выбранному набору сетей.
4. Сбор результатов экспериментов.
5. Публикация разработанных программ/скриптов в личном репозитории на GitHub.
6. Подготовка отчета, содержащего минимальный объем информации по каждому этапу выполнения работы.

Выполнение лабораторной работы осуществлено мною в Google Colab на языке программирования Python. Результаты и отчет размещены в личном профиле на GitHub, ссылка: <https://github.com/Olga-1911/Initial-tuning-of-weights-of-fully-connected-and-convolutional-neural-networks>.

В процессе выполнения лабораторной работы, мною были выполнены следующие шаги:

1. Для выполнения лабораторной работы № 5 я выбрала набор данных CIFAR-10 (Canadian Institute For Advanced Research) - это коллекция изображений, широко используемых в алгоритмах машинного обучения и компьютерного зрения. Он был разработан исследователями из института CIFAR и состоит из 60 000 цветных изображений размером 32x32 пикселя, разделенных на 10 классов. Этот набор данных я использовала при выполнении лабораторной работы № 3.

В лабораторной работе № 3 мною были разработаны, обучены и протестированы три нейронные сети для классификации изображений на датасете CIFAR-10, две полносвязные (FCNN) и одна сверточная (CNN): FCNN с 2 слоями (точность 43,07%), FCNN с 3 слоями (47,96%) и CNN (84,05%)

Модель: FCNN_2_layers, Время обучения: 1056.31 сек, Точность: 0.4307
Модель: FCNN_3_layers, Время обучения: 861.18 сек, Точность: 0.4796
Модель: CNN, Время обучения: 14881.19 сек, Точность: 0.8405

CNN (84.05%) явно лидирует по точности, подтверждая, что сверточные сети лучше подходят для классификации изображений, при этом время обучения модели – намного выше, что у полносвязных моделей FCNN. Для выполнения лабораторной работы я выбрала модель **FCNN с 3 слоями** (с минимальным временем обучения: 861.18 сек, точность: 47,96%) – в первой части лабораторной работы, а также модель **CNN** (время обучения: 14881.19 сек, точность: 0.8405) – во второй части лабораторной работы, т.к. модель FCNN с 3 слоями с применением методов обучения без учителя показали крайне низкую точность предсказания.

Для измерения точности использована метрика: Точность (ассигасу):

$$\text{Accuracy} = \frac{\text{Количество правильно классифицированных примеров}}{\text{Общее количество примеров}}$$

Точность измеряет долю правильных предсказаний на тестовом наборе.


2. Для выполнения настройки начальных значений весов сетей я выбрала 3 метода обучения без учителя: **автоэнкодеры, RBM и k-средних**.

3. Применение методов обучения без учителя к выбранному набору сетей, сбор и анализ результатов экспериментов.

В первой части лабораторной работы № 5 разработаны, обучены и протестированы модели с использованием полносвязной нейронной сети (Fully-connected neural network) **FCNN с 3 слоями** с применением 3-х

методов обучения без учителя: автоэнкодеры, RBM и k-средних, получены следующие результаты:


Base Model: 0.3171
Autoencoder: 0.1000
RBM: 0.4024
K-Means: 0.1000



Самая высокая точность – у модели RBM – 40,24%.

Модель «**RBM + FCNN с 3 слоями**» представляет собой гибридную структуру, включающую ограниченную машину Больцмана (RBM) и полносвязанную нейронную сеть (Fully Connected Neural Network, FCNN). Эта архитектура состоит из следующих основных элементов:

1. Ограниченная машина Больцмана (RBM):
 - используется для предварительного обучения и инициализации весов;
 - обеспечивает возможность эффективного извлечения признаков на начальном этапе обучения.
2. Полносвязанная нейронная сеть (FCNN):
 - включает три скрытых слоя;
 - каждый слой принимает вход от предыдущего и передает сигнал следующему слою;
 - применяется для классификации/регрессии на основе извлеченных признаков.



Представленные графики демонстрируют динамику обучения модели «**RBM + FCNN с 3 слоями**» на протяжении 15 эпох. Левый график отображает точность модели на обучающем и валидационном наборах данных, а правый график - соответствующие значения потерь.

Анализ графиков точности и потерь позволяет оценить эффективность обучения RBM и выявить признаки переобучения или недообучения.

На графике точности видно, что как точность на обучающем наборе, так и точность на валидационном наборе данных увеличиваются с каждой эпохой и достигают плато к 15 эпохе. Это свидетельствует об успешном обучении модели и ее способности обобщать знания на новые данные.


На графике потерь видно, что как потери на обучающем наборе, так и потери на валидационном наборе данных снижаются с каждой эпохой и достигают плато к 15 эпохе. Это подтверждает успешное обучение модели и ее способность минимизировать ошибку на данных.

В других двух моделях «**автоэнкодеры + FCNN с 3 слоями**» и «**k-средних + FCNN с 3 слоями**» наблюдается значительная разница между точностью на обучающем наборе и точностью на валидационном наборе, что указывает на признаки переобучения. Модели слишком хорошо адаптировались к обучающим данным, но теряют способность обобщать знания на новые, не виденные ранее данные.

Потери обучения также показывают колебания. Потери валидации изначально выше, чем потери обучения. Модель начинает хуже обобщать знания на валидационные данные после определенного момента.

Во второй части лабораторной работы № 5 разработаны, обучены и протестированы модели с использованием нейронной сети CNN (Convolutional Neural Network) с применением 3-х методов обучения без учителя: автоэнкодеры, RBM и k-средних, получены следующие результаты:

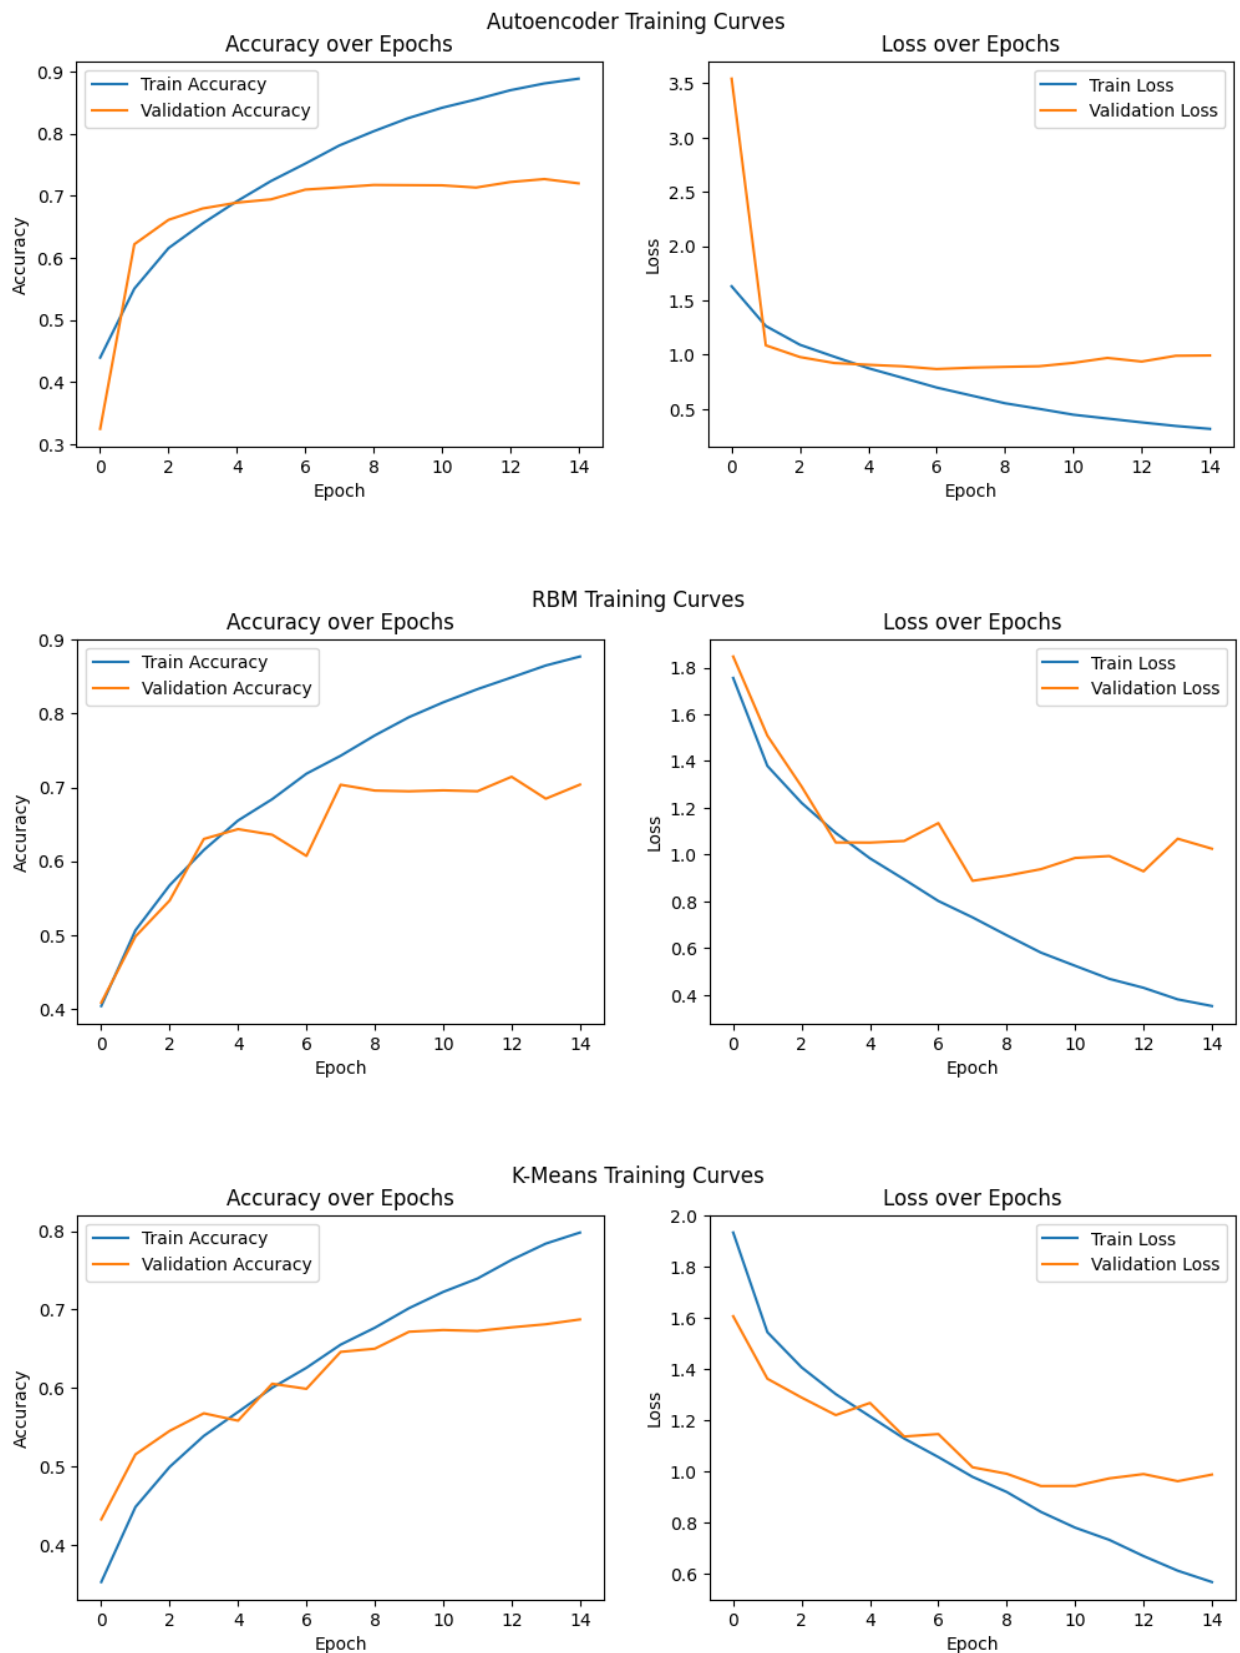
Test accuracy (Autoencoder): 0.7163
Test accuracy (RBM): 0.6980
Test accuracy (K-Means init): 0.6857



Самая высокая точность – у модели Autoencoder – 71,63%.

CNN (Convolutional Neural Network) - это тип искусственной нейронной сети, специально разработанный для обработки многомерных данных, таких как изображения, звук и другие сигналы, имеющие пространственную структуру. Название "свёрточная сеть" связано с использованием операции свёртки, позволяющей эффективно анализировать локальные особенности объектов. При обработке изображений эта нейронная сеть показывает более высокую точность, при этом время обучения значительно превышает FCNN.

Представленные графики демонстрируют динамику обучения моделей, представляющих собой нейронные сети CNN с использованием 3-х методов обучения без учителя: автоэнкодеры, RBM и k-средних.



На тестовой выборке, как мы уже обозначили ранее, лучшие результаты показала модель «автоэнкодеры + CNN» с точностью **71,63%**,

при этом вторые 2 модели – достаточно близки по точности к лидирующей: модель «**RBM + CNN**» - **69,80%**, модель «**k-средних + CNN**» - **68,57%**.

Во всех случаях точность на обучении (синий график «Train Accuracy») растёт почти монотонно с каждой эпохой.

Точность на валидации (оранжевый) сначала быстро растёт, а потом часто выходит на плато или даже слегка «проседает» - признак начала переобучения.

Значение функции потерь на обучении (синий «Train Loss») падает почти до нуля (или близко к нему), тогда как на валидации (оранжевый «Validation Loss») снижается менее интенсивно и затем может начать расти.

На автоэнкодере:

- Loss на обучении быстро уходит к нулю (модель учится «восстанавливать» свои же входы), а валидационные потери после быстрого падения немного растут (переобучение).

- Точность валидации достигает примерно 0,70–0,75, в то время как на обучении близка к 0,9.

На RBM (Restricted Boltzmann Machine):

- Потери на обучении тоже значительно падают, но валидационные потери остаются выше и сильно колеблются.

- Валидационная точность примерно 0,65–0,70, однако колебания говорят об нестабильности обучения.

На K-Means инициализация:

- Здесь обучаемая сеть инициализируется центрами кластеров (K-Means), из-за чего потери на обучении и валидации сходятся более стабильно.

- Валидационная точность растёт плавно до ~0,70–0,75 и затем слегка плато.

Вывод: перенос знаний (инициализация весов из RBM или K-Means) может ускорить или сделать более стабильным начало обучения, но без «тонкой донастройки» (fine-tuning) модель всё равно склонна к

переобучению. Автоэнкодер максимально быстро подгоняет себя под данные (минимизирует loss), но хуже генерализует на валидации, в то время как K-Means дает более ровный ландшафт потерь и точности.